

Redução de parâmetros das CNNs

Comparação camada a camada entre a busca de arquitetura original e a busca de redução — RadioML 2018.01A, grupo ASK (3 classes)

O diagnóstico

Na CNN da campanha, **99,9% dos parâmetros estão numa única camada**: a primeira *Linear*, logo após o *Flatten*. As convoluções somam 10.976 pesos; a densa sozinha, 8.389.120. Isso muda o que faz sentido otimizar — mexer nas convoluções não altera o tamanho do modelo de forma relevante.

A causa é geométrica. Duas camadas de *pooling* reduzem o comprimento de 1024 para 256, mas os canais sobem para 64. O *Flatten* entrega $64 \times 256 = 16.384$ valores, e uma camada densa custa **entrada x saída**: $16.384 \times 512 = 8,4$ milhões.

A mudança, em uma linha

A candidata **gap1** tem as convoluções **bit a bit idênticas** às da *2L_32-64*. A única diferença é um *AdaptiveAvgPool1d(1)* inserido antes do *Flatten* — uma média, **sem nenhum parâmetro**.

ANTES — 2L_32-64, a menor das 12 candidatas da busca original

camada	saída	parâmetros
Conv1d k=7	(32, 1024)	480
BatchNorm1d	(32, 1024)	64
MaxPool1d	(32, 512)	-
Conv1d k=5	(64, 512)	10,304
BatchNorm1d	(64, 512)	128
MaxPool1d	(64, 256)	-
Flatten	(16384,)	-
Linear 16384->512	(512,)	8,389,120
Linear 512->3	(3,)	1,539
TOTAL		8,401,635

DEPOIS — gap1, mesmo tronco convolucional + pooling global

camada	saída	parâmetros
Conv1d k=7	(32, 1024)	480
BatchNorm1d	(32, 1024)	64
MaxPool1d	(32, 512)	-
Conv1d k=5	(64, 512)	10,304
BatchNorm1d	(64, 512)	128
MaxPool1d	(64, 256)	-
AdaptiveAvgPool1d(1)	(64, 1)	-
Flatten	(64,)	-
Linear 64->512	(512,)	33,280
Linear 512->3	(3,)	1,539
TOTAL		45,795

Compare as duas tabelas: as seis primeiras linhas são iguais. Entra o *AdaptiveAvgPool1d(1)*, e as 16.384 features viram 64. A densa cai de 8.389.120 para 33.280 pesos. Foram **8.355.840 parâmetros removidos por uma operação que não tem peso nenhum**.

O que o pooling global descarta

Depois das convoluções há 64 canais x 256 instantes. Cada canal é um detector: responde a um padrão no sinal, e a saída diz *quanto* e *onde* ele apareceu.

	o que preserva	features
Flatten	quanto E onde (256 instantes por canal)	16.384
AdaptiveAvgPool1d(1)	só quanto (média do canal)	64

Para classificação de modulação isso é defensável: uma constelação QAM se define pela *presença* de certas características, não por elas ocorrerem no instante 137. A capacidade removida estava sendo usada em boa parte para memorizar posição.

Por que a busca original mal alterava o tamanho

A arquitetura mais profunda entre as 12 tem cinco blocos convolucionais e canais até 1024 — muito mais convolução que a menor. Ainda assim, o que domina o total continua sendo a densa.

5L_64-128-256-512-1024 — a mais profunda das 12

camada	saída	parâmetros
Conv1d k=11	(64, 1024)	1,472
BatchNorm1d	(64, 1024)	128
MaxPool1d	(64, 512)	-
Conv1d k=7	(128, 512)	57,472
BatchNorm1d	(128, 512)	256
MaxPool1d	(128, 256)	-
Conv1d k=5	(256, 256)	164,096
BatchNorm1d	(256, 256)	512
MaxPool1d	(256, 128)	-
Conv1d k=3	(512, 128)	393,728
BatchNorm1d	(512, 128)	1,024
MaxPool1d	(512, 64)	-
Conv1d k=3	(1024, 64)	1,573,888
BatchNorm1d	(1024, 64)	2,048
MaxPool1d	(1024, 32)	-
Flatten	(32768,)	-
Linear 32768->512	(512,)	16,777,728
Linear 512->3	(3,)	1,539
TOTAL		18,973,891

	2L_32-64	5L_64-...-1024
Convoluções	10,976	2,194,624
Primeira densa	8,389,120	16,777,728
Total	8,401,635	18,973,891

Acrescentar três camadas e multiplicar os canais por 16 somou 2,2 milhões nas convoluções. Mas a densa **sozinha** saltou de 8,4 para 16,8 milhões, porque cinco *poolings* deixam 1024 canais x 32 instantes = 32.768 features.

Consequência para o estudo: nas 12 candidatas, a diferença de capacidade vinha quase toda de um efeito colateral da profundidade sobre a largura da última camada convolucional — não da profundidade em si, que era o objeto da comparação.

As oito candidatas da busca de redução

Todas partem do mesmo tronco 2L_32-64 (exceção: 6pools). Ordenadas da menor para a maior, como são executadas.

#	candidata	transição para a densa	parâmetros	densas
1	gap1	AdaptiveAvgPool1d(1) -> 64 -> 512	45,795	76.0%
2	gap8_head128	AdaptiveAvgPool1d(8) -> 512 -> 128	77,027	85.8%
3	gap4	AdaptiveAvgPool1d(4) -> 256 -> 512	144,099	92.4%
4	gap8	AdaptiveAvgPool1d(8) -> 512 -> 512	275,171	96.0%
5	6pools	Flatten -> 1024 -> 512	595,427	88.4%
6	head64	Flatten -> 16384 -> 64	1,059,811	99.0%
7	head128	Flatten -> 16384 -> 128	2,108,643	99.5%
8	baseline_2L_512	Flatten -> 16384 -> 512	8,401,635	99.9%

As candidatas *head64* e *head128* existem para mostrar o caminho **fraco**: elas não mexem nas 16.384 features, só encurtam o destino. Mesmo indo para 64 unidades sobra mais de 1 milhão de parâmetros, porque o gargalo é a dimensão de *entrada* da densa.

Repare na última coluna: conforme o modelo encolhe, as densas deixam de dominar. No *baseline* são 99,9% do modelo; na *gap1*, 76% — e a rede passa a ser majoritariamente convolucional.

Resultados medidos até agora

modelo	parâmetros	melhor val_acc (ASK)
2L_32-64 (baseline)	8,401,635	88,30%
gap1, lr 4.5e-5, teto 120 ep.	45,795	88,49% a 92,02%
gap1, lr 4.5e-4, sem teto	45,795	96,20%
ResNet do artigo	212,547	93,00% (época 7)

Ressalvas. Um fold por linha, no grupo mais fácil (ASK, 3 classes). As outras sete candidatas ainda não rodaram no regime atual. A dispersão entre folds observada no regime anterior foi de 3,5 pontos percentuais — maior que quase todas as diferenças que a busca original media entre arquiteturas, o que sugere que cinco folds podem ser poucos para distinguir candidatas.