

**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA**

CEFET/RJ

**JOÃO MARCO PEREIRA
RICARDO ALEXANDRE VIEIRA DA SILVA**

**CLASSIFICAÇÃO AUTOMÁTICA DE
MODULAÇÕES EM AMBIENTES DE INTERNET
DAS COISAS UTILIZANDO APRENDIZADO DE
MÁQUINA**

**Rio de Janeiro
2026**

JOÃO MARCO PEREIRA
RICARDO ALEXANDRE VIEIRA DA SILVA

CLASSIFICAÇÃO AUTOMÁTICA DE MODULAÇÕES EM AMBIENTES DE INTERNET DAS COISAS UTILIZANDO APRENDIZADO DE MÁQUINA

Relatório Inicial de Iniciação Científica apresentado ao Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET/RJ) como parte das atividades de pesquisa.

Orientador: Prof. Dr. Rafael da Silva Chaves

Rio de Janeiro
2026

1 Introdução

O avanço das tecnologias de comunicação sem fio tem impulsionado o crescimento acelerado da Internet das Coisas (*Internet of Things* – IoT), na qual diversos dispositivos heterogêneos compartilham o espectro de radiofrequência para transmissão de dados. Nesse contexto, sensores, atuadores e sistemas embarcados empregam diferentes técnicas de modulação, escolhidas de acordo com requisitos de taxa de transmissão, robustez a ruído, consumo energético e complexidade de implementação.

A identificação automática do tipo de modulação de um sinal recebido constitui uma tarefa fundamental para aplicações como monitoramento espectral, comunicações cognitivas, segurança e gerenciamento eficiente de redes IoT. Abordagens tradicionais de reconhecimento automático de modulação, embora frequentemente utilizem classificadores baseados em aprendizado de máquina, dependem fortemente da extração manual de características estatísticas e de pressupostos prévios sobre o canal de comunicação. Nessas abordagens, o aprendizado ocorre de forma limitada à etapa de decisão, enquanto a representação do sinal é definida a priori, o que restringe a capacidade de generalização em ambientes reais, dinâmicos e sujeitos a diferentes condições de canal.

Com o avanço do aprendizado de máquina, em especial das técnicas de aprendizado profundo, tornou-se possível desenvolver modelos capazes de aprender, de forma conjunta, tanto a extração de características quanto a classificação diretamente a partir dos sinais brutos. Essa abordagem fim-a-fim reduz a necessidade de engenharia manual de características e tende a apresentar maior robustez frente a ruído, desvanecimento e imperfeições práticas do sistema de comunicação.

2 Tema

Este trabalho tem como tema o desenvolvimento de modelos de aprendizado de máquina para a classificação automática de modulações de sinais de comunicação em ambientes de Internet das Coisas. O foco está na utilização de técnicas de aprendizado supervisionado capazes de operar diretamente sobre amostras de sinais recebidos, visando identificar o esquema de modulação empregado pelo dispositivo transmissor.

3 Justificativa

A crescente densidade de dispositivos IoT e a diversidade de protocolos de comunicação tornam o ambiente de rádio cada vez mais complexo e dinâmico. Nesse contexto, a identificação do tipo de modulação de sinais recebidos passa a ser um desafio relevante, sobretudo na presença de ruído, interferência, desvanecimento e imperfeições de sincronização, condições típicas de sistemas de comunicação sem fio.

Nesse cenário, a classificação automática de modulações constitui um problema central em diversas aplicações de monitoramento e análise espectral, demandando métodos capazes de lidar com sinais heterogêneos e condições variáveis de canal. Abordagens baseadas em técnicas computacionais vêm sendo amplamente investigadas como alternativa aos métodos clássicos, buscando maior flexibilidade na modelagem do sinal e melhor desempenho frente à variabilidade das condições de transmissão.

Dessa forma, este trabalho é motivado pela investigação e avaliação de diferentes modelos de aprendizado de máquina aplicados à classificação de modulações em ambientes IoT, com o objetivo de analisar suas capacidades, limitações e potencial de aplicação em sistemas modernos de comunicação.

4 Objetivo

O objetivo geral deste projeto de Iniciação Científica é desenvolver e avaliar modelos de aprendizado de máquina capazes de classificar automaticamente o tipo de modulação de um sinal recebido em um ambiente de Internet das Coisas, considerando a presença de múltiplos dispositivos e diferentes esquemas de modulação.

Como objetivos específicos, destacam-se:

- estudar técnicas de aprendizado de máquina aplicadas à classificação de sinais de comunicação;
- implementar e treinar modelos de aprendizado supervisionado para identificação de modulações;
- avaliar o desempenho dos modelos em cenários com ruído e diferentes condições de canal.

5 Bases de Dados Consideradas

O desempenho de modelos de aprendizado de máquina aplicados à classificação automática de modulações depende fortemente da qualidade e diversidade dos dados utilizados. Assim, nesta etapa inicial do projeto, foram analisadas bases de dados amplamente utilizadas na literatura de *Automatic Modulation Recognition* (AMR).

5.1 RadioModRec-1

O dataset *RadioModRec-1* é uma base sintética que contempla quinze esquemas de modulação digital, incluindo PSK, QAM e FSK, sob diferentes condições de canal, como AWGN e desvanecimento Rayleigh e Rician, com SNR variando de -20 dB a +20 dB. Apesar da diversidade de condições simuladas .

5.2 AugMod (Pythagore-Mod-Reco)

O conjunto *AugMod* é composto por sinais representados por amostras I/Q, organizados em arquivos HDF5, abrangendo sete classes de modulação e cinco níveis de SNR. Embora adequado para validação inicial de arquiteturas leves, seu número reduzido de classes limita sua representatividade para ambientes IoT complexos.

5.3 DeepSig RadioML 2018.01A

O dataset *RadioML 2018.01A*, desenvolvido pela DeepSig Inc., foi selecionado para este projeto. Ele contém aproximadamente 2,5 milhões de exemplos, com 24 tipos de modulação analógica e digital, representados por séries temporais de 1024 amostras I/Q. A base inclui ampla variação de SNR (-20 dB a +30 dB) e efeitos realistas de canal .

Trabalhos como o de O'Shea et al. (2017) indicam que esse dataset é adequado para a avaliação de métodos de reconhecimento automático de modulação sob diferentes condições de canal e níveis de SNR. Dessa forma, sua utilização neste trabalho permite uma análise consistente e alinhada com estudos prévios, mostrando-se coerente com os objetivos propostos.

6 Modelos Avaliados

Nesta etapa, foram avaliados diferentes modelos supervisionados para classificação de modulações a partir de sinais I/Q. Todos os modelos foram treinados utilizando apenas amostras com SNR de 20 dB e 30 dB, visando uma análise inicial em condições favoráveis de recepção.


6.1 Perceptron Multicamadas (MLP)

O modelo MLP foi utilizado como abordagem inicial, operando sobre vetores unidimensionais obtidos a partir das amostras I/Q.

6.1.1 Resultados e Discussão

Após ajuste de hiperparâmetros via *Grid Search*, o MLP alcançou uma acurácia de aproximadamente 29%, apresentando bom desempenho apenas para modulações de baixa complexidade.

Figura 1: Matriz de confusão do modelo Perceptron Multicamadas (MLP).



Fonte: Elaborado pelo autor (2026).

6.2 Gradient Boosting com Árvores de Decisão (LightGBM)

O modelo LightGBM foi avaliado como alternativa baseada em árvores de decisão, com ajuste de hiperparâmetros via *Randomized Search*.

6.2.1 Resultados e Discussão

O LightGBM obteve uma acurácia de aproximadamente 44%, superando o MLP. Embora tenha apresentado melhorias significativas, o modelo ainda demonstrou dificuldades em distinguir modulações de alta ordem .

Figura 2: Matriz de confusão do modelo LightGBM.



Fonte: Elaborado pelo autor (2026).

6.3 Rede Neural Convolucional (CNN)

A Rede Neural Convolucional (CNN) foi treinada diretamente sobre as séries temporais I/Q, preservando sua estrutura bidimensional. A arquitetura adotada corresponde a um modelo convolucional básico, utilizado como ponto de partida para a análise do desempenho de redes profundas na tarefa de classificação de modulações.

Esse modelo inicial foi projetado com o objetivo de avaliar a capacidade das camadas convolucionais em extrair padrões temporais relevantes dos sinais, sem o uso de técnicas avançadas de otimização arquitetural. Assim, a CNN empregada deve ser interpretada como uma arquitetura de referência, servindo de base para comparações futuras com modelos mais complexos.

A Tabela 1 apresenta o resumo da arquitetura da CNN, conforme gerado pela função *model.summary()*, destacando as camadas convolucionais, operações de *pooling*, camadas totalmente conectadas e o número total de parâmetros treináveis.

Tabela 1: Resumo da arquitetura da Rede Neural Convolucional (CNN) utilizada.

Camada (Tipo)	Dimensão de Saída	Parâmetros
Conv1D (64 filtros)	(None, 1022, 64)	448
MaxPooling1D	(None, 511, 64)	0
Dropout	(None, 511, 64)	0
Conv1D (128 filtros)	(None, 509, 128)	24 704
MaxPooling1D	(None, 254, 128)	0
Dropout	(None, 254, 128)	0
Conv1D (256 filtros)	(None, 252, 256)	98 560
MaxPooling1D	(None, 126, 256)	0
Dropout	(None, 126, 256)	0
Flatten	(None, 32 256)	0
Dense (512 neurônios)	(None, 512)	16 515 584
Dropout	(None, 512)	0
Dense (24 classes)	(None, 24)	12 312
Total de parâmetros treináveis		16 651 608


Fonte: Elaborado pelo autor (2026).

6.3.1 Resultados e Discussão

Mesmo utilizando uma arquitetura básica, a CNN alcançou uma acurácia de aproximadamente 78.6%, superando de forma significativa os modelos MLP e LightGBM. Esse resultado evidencia a eficiência das camadas convolucionais na extração automática de características discriminativas diretamente a partir dos sinais I/Q.

O desempenho obtido indica que, mesmo sem refinamentos arquiteturais, a CNN é capaz de capturar padrões temporais relevantes associados aos diferentes esquemas de modulação, reforçando sua adequação para tarefas de reconhecimento automático de modulações. Esses resultados motivam a investigação futura de arquiteturas mais profundas e especializadas, visando ganhos adicionais de desempenho.

Figura 3: Matriz de confusão do modelo de Rede Neural Convolucional (CNN).



Fonte: Elaborado pelo autor (2026).

7 Avaliação por Grupos de Modulação

Com base nos resultados obtidos na etapa anterior, foi conduzida uma análise mais detalhada da capacidade de classificação da CNN por família de modulação. Para tanto, as 24 classes do dataset *RadioML 2018.01A* foram organizadas em seis grupos, conforme apresentado na Tabela 2, e o pipeline de treinamento foi estendido para permitir a seleção de grupos específicos ou de todos os grupos simultaneamente.

Tabela 2: Grupos de modulação do dataset RadioML 2018.01A.

Grupo	Modulações
ASK	OOK, 4ASK, 8ASK
PSK	BPSK, QPSK, 8PSK, 16PSK, 32PSK, GMSK, OQPSK
APSK	16APSK, 32APSK, 64APSK, 128APSK
QAM	16QAM, 32QAM, 64QAM, 128QAM, 256QAM
AM	AM-SSB-WC, AM-SSB-SC, AM-DSB-WC, AM-DSB-SC
FM	FM

Fonte: Elaborado pelo autor (2026).

7.1 Pré-processamento


Para esta etapa, o pipeline de pré-processamento foi adaptado em relação à abordagem anterior. As principais modificações introduzidas foram:

- **Filtragem por SNR:** as amostras foram filtradas considerando a faixa de 0 dB a +30 dB, ampliando o intervalo de condições de canal avaliadas em comparação com a etapa inicial, na qual apenas SNRs de 20 dB e 30 dB eram utilizados;
- **Extração de subconjuntos:** foram criados datasets menores com SNRs específicos, possibilitando análises isoladas por nível de relação sinal-ruído;
- **Remapeamento de *labels*:** os índices globais das 24 classes foram convertidos para índices locais por grupo de modulação, etapa necessária quando o treinamento é realizado sobre subconjuntos do dataset;
- **Divisão dos dados:** os dados foram particionados em conjuntos de treino (60%), validação (20%) e teste (20%), com estratificação por classe para garantir distribuição balanceada entre os conjuntos;
- **Reprodutibilidade:** foi utilizada semente aleatória fixa ($seed = 42$) em todas as etapas de embaralhamento e divisão dos dados.

7.2 Resultados e Discussão

A Figura 4 apresenta as curvas de acurácia em função do SNR obtidas para cada grupo de modulação. De forma geral, todos os grupos apresentam acurácias crescentes com o aumento do SNR, comportamento esperado, uma vez que sinais com maior relação sinal-ruído possuem características espectrais e temporais mais discriminativas. Observa-se, contudo, que a taxa de crescimento e o patamar de acurácia atingido variam consideravelmente entre os grupos, refletindo diferenças na complexidade intrínseca de cada família de modulação e na similaridade entre as classes que a compõem.

Figura 4: Acurácia em função do SNR para cada grupo de modulação.




Fonte: Elaborado pelo autor (2026).

A Figura 5 apresenta as matrizes de confusão obtidas para cada grupo de modulação. A análise por grupo permite identificar, com maior granularidade, as classes que apresentam maior taxa de confusão mútua. Em particular, modulações de alta ordem, como as pertencentes aos grupos QAM e APSK, tendem a apresentar confusões entre classes adjacentes, cujas constelações se tornam mais similares em baixas SNRs. Já grupos com menor número de classes, como AM e FM, tendem a apresentar separação mais nítida entre os esquemas de modulação.

Figura 5: Matrizes de confusão por grupo de modulação.

Matrizes de Confusão — Todos os Modelos




Fonte: Elaborado pelo autor (2026).

A Figura 6 sintetiza o desempenho dos modelos avaliados ao longo de todas as etapas do projeto, permitindo uma comparação direta entre as abordagens investigadas. Os resultados confirmam a superioridade da CNN frente aos métodos clássicos de aprendizado de máquina e evidenciam que a análise por grupo de modulação fornece informações complementares relevantes para a compreensão das limitações de cada modelo frente à diversidade de esquemas presentes no dataset.

Figura 6: Comparação de desempenho entre os modelos testados.

Avaliação por Modelo — Matriz de Confusão + Acurácia x SNR



8 Busca de Arquiteturas da CNN com Validação Cruzada K-Fold

Dando continuidade à avaliação por grupos de modulação, a etapa mais recente do projeto consistiu em uma busca sistemática de arquiteturas de CNN unidimensional (1D), conduzida de forma independente para cada grupo de modulação. O objetivo desta busca é identificar, para cada família de modulação, a arquitetura que oferece o melhor compromisso entre acurácia, estabilidade entre execuções e número de parâmetros, substituindo a arquitetura única de referência utilizada nas etapas anteriores.

8.1 Metodologia da Busca

O espaço de busca é composto por arquiteturas convolucionais formadas por blocos $\text{Conv1D} + \text{Batch Normalization} + \text{ReLU} + \text{MaxPooling}$, variando-se o número de camadas convolucionais (de 2 a 6) e a quantidade de filtros por camada. Adota-se a notação $nL_f_1-f_2-\dots$ para identificar cada arquitetura: por exemplo, $2L_32-64$ denota uma rede com duas camadas convolucionais, com 32 e 64 filtros, respectivamente. Todas as arquiteturas compartilham o mesmo classificador denso (camada oculta de 512 neurônios com *dropout* de 0,5) e o mesmo protocolo de treinamento: otimização com taxa de aprendizado inicial de 10^{-3} , redução da taxa via *ReduceLROnPlateau* (paciência de 5 épocas) e parada antecipada (*early stopping*) após 15 épocas sem melhoria.

A avaliação de cada arquitetura é feita por validação cruzada *k-fold* com $k = 5$, com sementes fixas por *fold* para garantir reprodutibilidade. A métrica adotada é a melhor acurácia de validação atingida em cada *fold*; a comparação entre arquiteturas utiliza a média, o máximo, o mínimo e o desvio-padrão dessa métrica ao longo dos 5 *folds*. A análise da dispersão entre *folds* é particularmente importante, pois permite distinguir arquiteturas consistentemente boas de arquiteturas que apenas ocasionalmente atingem acurácias elevadas.

8.2 Infraestrutura de Experimentação

Como os treinamentos são executados em ambiente de nuvem (Google Colab) em sessões sujeitas a interrupção, foi implementada uma infraestrutura de persistência e análise dos resultados:

- ao final de cada *fold*, os resultados (histórico de treinamento por época, melhor acurácia de validação, número de parâmetros e hiperparâmetros utilizados) são gravados em arquivos JSON por grupo de modulação e sincronizados com o Google Drive, permitindo retomar a busca de onde parou;

- periodicamente são gerados *backups* locais (arquivos ZIP das sessões), que preservam resultados mesmo em caso de perda ou sobrescrita dos arquivos no Drive;
- um *pipeline* local de análise, em modo somente leitura, reúne os resultados das duas fontes (Drive e *backups* locais) e utiliza, para cada grupo, a fonte mais completa — aquela com maior número de *folds* concluídos e, em caso de empate, a mais recente. De fato, os resultados dos grupos ASK e PSK foram recuperados exclusivamente dos *backups* locais, pois não estavam mais disponíveis no Drive;
- a partir dos dados consolidados, o *pipeline* regenera automaticamente os gráficos, a tabela de resultados e uma apresentação de acompanhamento, sem qualquer edição manual de números ou conclusões.

8.3 Estado Atual da Busca

A Tabela 3 resume o estado atual da busca em cada grupo de modulação. A cobertura é heterogênea: os grupos ASK, PSK e AM já possuem as 12 arquiteturas do espaço de busca avaliadas com os 5 *folds* completos, o grupo APSK conta com 5 arquiteturas avaliadas (24 *folds*), o grupo QAM conta apenas com a primeira arquitetura avaliada e o grupo FM ainda não foi iniciado.

Tabela 3: Estado atual da busca de arquiteturas por grupo de modulação.


Grupo	Arquiteturas	Folds	Melhor arquitetura	Acc. média (%)
ASK	12	60	6L_64-64-128-128-256-512_mixpool	97,80
PSK	12	60	2L_32-64	68,21
APSK	5	24	2L_32-64	25,00
QAM	1	5	2L_32-64	20,00
AM	12	60	2L_64-128	77,99
FM	—	—	sem resultados até o momento	

Fonte: Elaborado pelo autor (2026).

8.4 Resultados e Discussão


Grupo ASK. O grupo ASK apresenta os melhores resultados da busca até o momento. Como mostram as Figuras 7 e 8, todas as 12 arquiteturas superam 93% de acurácia média, e as redes com 4 ou mais camadas convolucionais saturam em um patamar entre 97,6% e 97,8%, com desvios-padrão inferiores a 0,2 ponto percentual. A melhor arquitetura, 6L_64-64-128-128-256-512_mixpool, atinge 97,80% de média. O ganho marginal entre 4 e 6 camadas é pequeno, o que sugere que, para este grupo, arquiteturas intermediárias como 4L_32-64-128-256 (97,62% com cerca de metade dos parâmetros) oferecem melhor custo-benefício.

Figura 7: Grupo ASK: acurácia de validação por época (melhor *fold* de cada arquitetura).



Fonte: Elaborado pelo autor (2026).

Figura 8: Grupo ASK: número de parâmetros *versus* acurácia média de validação.




Fonte: Elaborado pelo autor (2026).

Grupo PSK. O grupo PSK revelou o comportamento mais instável da busca. Como ilustram as Figuras 9 e 10, diversas arquiteturas alternam, entre *folds*, resultados excelentes (acima de 95%, como 6L_32-64-64-128-256-512_mixpool com máximo de 96,22%


e 4L_32-64-128-256 com máximo de 96,00%) e resultados presos em 14,29% — exatamente o nível de acerto aleatório para as 7 classes do grupo — produzindo desvios-padrão de até 39,9 pontos percentuais. Quatro arquiteturas ficaram no nível de chance em todos os *folds*. Esse padrão indica que a dificuldade não é de capacidade de representação, mas de otimização: dependendo da inicialização, o treinamento colapsa para uma solução degenerada e não se recupera. A investigação de estratégias de estabilização (aquecimento da taxa de aprendizado, reinicialização de *folds* colapsados, normalização dos sinais) é o próximo passo natural para este grupo.

Figura 9: Grupo PSK: acurácia de validação por época (melhor *fold* de cada arquitetura).



Fonte: Elaborado pelo autor (2026).


Figura 10: Grupo PSK: acurácia de validação por época (pior *fold* de cada arquitetura), evidenciando os *folds* colapsados no nível de acerto aleatório (14,29%).



Fonte: Elaborado pelo autor (2026).

Grupo AM. No grupo AM, com as 12 arquiteturas do espaço de busca avaliadas nos 5 *folds*, a rede rasa 2L_64-128 lidera com 77,99% de acurácia média, seguida de perto por 2L_32-64 (77,51%). Conforme a Figura 11, o aumento de profundidade e de número de parâmetros não traz ganho consistente: as duas piores médias pertencem justamente às redes mais profundas ou maiores — 5L_32-64-128-256-512 (71,70%) e 3L_128-256-512 (72,24%, com 34,1 milhões de parâmetros e desvio-padrão de 6,02 p.p.). A exceção é 4L_128-256-512-512, que atinge 77,17% de média, mas com a maior dispersão do grupo (desvio-padrão de 6,99 p.p., mínimo de 63,69%), o que a torna pouco confiável frente às redes rasas. Para este grupo, os resultados indicam que arquiteturas compactas são preferíveis, e que o patamar em torno de 78% é consistente com a acurácia obtida pela CNN de referência na etapa anterior.

Figura 11: Grupo AM: número de parâmetros *versus* acurácia média de validação.



Fonte: Elaborado pelo autor (2026).

Grupos APSK e QAM. Os grupos APSK e QAM apresentam um comportamento que merece atenção. No grupo APSK, as 5 arquiteturas já avaliadas (24 *folds* concluídos) permaneceram todas estacionadas em 25,00% — o nível de acerto aleatório para as 4 classes do grupo, com desvio-padrão nulo. No grupo QAM, ainda no início da busca, a arquitetura 2L_32-64 apresentou o mesmo padrão, estacionada em 20,00% (5 classes). Diferentemente do grupo PSK, em que ao menos parte dos *folds* converge, nesses grupos nenhum *fold* escapou do nível de chance; o fato de o comportamento se repetir em 5 arquiteturas distintas no APSK reforça a hipótese de um problema sistemático na etapa de treinamento desses subconjuntos (por exemplo, no remapeamento de *labels*, na normalização dos sinais ou na adequação da taxa de aprendizado), e não de insuficiência da arquitetura. O diagnóstico desse comportamento é prioridade antes de estender a busca a arquiteturas maiores nesses grupos.

8.5 Resultados Consolidados

As Tabelas 4 e 5 consolidam todos os resultados obtidos até o momento, por grupo e arquitetura, ordenados por acurácia média decrescente dentro de cada grupo.

Tabela 4: Resultados da busca de arquiteturas — grupos ASK e PSK (5 *folds* por arquitetura).

Grupo	Arquitetura	Parâmetros	Média (%)	Máx (%)	Mín (%)	Desv. (p.p.)
ASK	6L_64-64-128-128-256-512_mixpool	17.394.435	97,80	97,93	97,73	0,07
ASK	6L_32-64-64-128-256-512_mixpool	17.334.051	97,71	97,76	97,64	0,04
ASK	5L_32-64-128-256-512	8.941.155	97,70	97,81	97,57	0,08
ASK	5L_64-128-256-512-1024	18.973.891	97,66	97,82	97,45	0,15
ASK	4L_32-64-128-256	8.546.403	97,62	97,73	97,57	0,07
ASK	4L_64-128-256-512	17.397.955	97,62	97,69	97,56	0,05
ASK	4L_128-256-512-512	18.457.475	97,62	97,69	97,58	0,04
ASK	3L_64-128-256	16.920.771	97,09	97,22	96,96	0,10
ASK	3L_128-256-512	34.118.019	97,07	97,35	96,90	0,16
ASK	3L_32-64-128	8.426.595	96,95	97,19	96,81	0,14
ASK	2L_64-128	16.821.699	93,74	94,30	93,03	0,42
ASK	2L_32-64	8.401.635	93,28	93,95	92,99	0,36
PSK	2L_32-64	8.403.687	68,21	83,51	57,15	9,61
PSK	3L_32-64-128	8.428.647	53,26	84,92	14,29	26,55
PSK	4L_32-64-128-256	8.548.455	46,89	96,00	14,29	39,94
PSK	6L_32-64-64-128-256-512_mixpool	17.336.103	42,10	96,22	14,29	34,95
PSK	2L_64-128	16.823.751	36,91	42,90	14,29	11,31
PSK	5L_32-64-128-256-512	8.943.207	30,61	95,91	14,29	32,65
PSK	6L_64-64-128-128-256-512_mixpool	17.396.487	25,71	71,39	14,29	22,84
PSK	3L_128-256-512	34.120.071	20,00	42,85	14,29	11,42
PSK	3L_64-128-256	16.922.823	14,29	14,29	14,29	0,00
PSK	4L_64-128-256-512	17.400.007	14,29	14,29	14,29	0,00
PSK	4L_128-256-512-512	18.459.527	14,29	14,29	14,29	0,00
PSK	5L_64-128-256-512-1024	18.975.943	14,29	14,29	14,29	0,00

Fonte: Elaborado pelo autor (2026).

Tabela 5: Resultados da busca de arquiteturas — grupos APSK, QAM e AM.

Grupo	Arquitetura	Parâmetros	Folds	Média (%)	Máx (%)	Mín (%)	Desv. (p.p.)
APSK	2L_32-64	8.402.148	5	25,00	25,01	25,00	0,00
APSK	2L_64-128	16.822.212	5	25,00	25,00	25,00	0,00
APSK	3L_32-64-128	8.427.108	5	25,00	25,00	25,00	0,00
APSK	3L_64-128-256	16.921.284	5	25,00	25,00	25,00	0,00
APSK	3L_128-256-512	34.118.532	4	25,00	25,00	25,00	0,00
QAM	2L_32-64	8.402.661	5	20,00	20,00	20,00	0,00
AM	2L_64-128	16.822.212	5	77,99	79,40	76,46	0,95
AM	2L_32-64	8.402.148	5	77,51	78,64	75,36	1,14
AM	4L_128-256-512-512	18.457.988	5	77,17	82,60	63,69	6,99
AM	3L_64-128-256	16.921.284	5	76,86	78,07	74,69	1,20
AM	3L_32-64-128	8.427.108	5	76,37	77,94	74,73	1,04
AM	6L_32-64-64-128-256-512_mixpool	17.334.564	5	75,37	78,84	72,46	2,22
AM	5L_64-128-256-512-1024	18.974.404	5	74,75	80,69	64,51	5,80
AM	4L_32-64-128-256	8.546.916	5	74,39	77,05	71,71	2,05
AM	4L_64-128-256-512	17.398.468	5	74,22	76,72	72,17	1,63
AM	6L_64-64-128-128-256-512_mixpool	17.394.948	5	73,12	77,77	69,27	3,27
AM	3L_128-256-512	34.118.532	5	72,24	77,44	63,11	6,02
AM	5L_32-64-128-256-512	8.941.668	5	71,70	74,98	67,33	2,72

Fonte: Elaborado pelo autor (2026).

8.6 Próximos Passos

Com base no estado atual da busca, os próximos passos definidos são: (i) diagnosticar e corrigir o colapso de treinamento observado nos grupos APSK e QAM, antes de prosseguir com as arquiteturas restantes nesses grupos; (ii) investigar estratégias de estabilização da otimização no grupo PSK, cuja variância entre *folds* domina a comparação entre arquiteturas; (iii) completar a busca nos grupos APSK e QAM e iniciá-la no grupo FM; e (iv) consolidar, para cada grupo, a arquitetura selecionada, avaliando-a no conjunto de teste reservado e em diferentes níveis de SNR.

Referências

O'SHEA, T. J.; ROY, T.; CLANCY, T. C. *Over-the-Air Deep Learning Based Radio Signal Classification*. IEEE Journal of Selected Topics in Signal Processing, v. 12, n. 1, p. 168–179, fev. 2018. DOI: 10.1109/JSTSP.2018.2797022.

ASP MRLAB. *RadioModRec: Radio Modulation Recognition Dataset*. Disponível em: <<https://www.kaggle.com/datasets/aspmirlab/radiomodrec>>. Acesso em: 2026.

HDUMASDE. *PythagoreModReco Dataset*. Disponível em: <<https://www.kaggle.com/datasets/hdumasde/pythagoremodreco>>. Acesso em: 2026.

PINXAU1000. *RadioML 2018 Dataset*. Disponível em: <<https://www.kaggle.com/datasets/pinxau1000/radioml2018>>. Acesso em: 2026.